

Negative Binomial Regression

Jieun Shin

2023-04-29

1. 음이항 회귀모형

y 를 음이항 분포를 따르는 계수형 (count) 값이라 하자. 포아송 분포에서는 평균과 분산이 같지만, 음이항 분포에서는 평균이 분산보다 작다고 가정한다. 음이항 모형은 (1)반응변수 y 가 어떤 사건이나 현상에 대한 계수값을 가지고 (2) 음이항 분포를 구성하는 모수를 가지는 일반화 선형모형 (GLM; generalized linear model)이다. y 의 평균 μ 와 산포모수 $\alpha > 0$ 를 갖는 음이항 분포는 다음과 같이 정의된다.

$$f(y) = \mathbb{P}(Y = y) = \frac{\Gamma(y + \frac{1}{\alpha})}{\Gamma(y + 1)\Gamma(\frac{1}{\alpha})} \left(\frac{1}{1 + \alpha\mu} \right)^{\frac{1}{\alpha}} \left(\frac{\alpha\mu}{1 + \alpha\mu} \right)^y$$

연결함수 (link function)에 의해 $\ln \mu = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p$ 로 표현되고 여기서 X_1, X_2, \cdots, X_p 는 독립변수, $\beta_1, \beta_2, \cdots, \beta_p$ 는 회귀계수이다. 각 변수는 n 개의 관측값 $(x_{1j}, x_{2j}, \cdots, x_{nj})^T$ 을 가지고, $\boldsymbol{\beta} = (\beta_0, \beta_1, \cdots, \beta_p)^T$ 는 모수벡터라 하자. 그러면 설계행렬 (design matrix) \mathbf{X} 는

$$\mathbf{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}$$

와 같이 나타내어진다. 음이항 분포를 $i = 1, 2, \dots, n$ 번째 관측치에 대하여

$$\begin{aligned} f(y_i) = \mathbb{P}(Y = y_i) &= \frac{\Gamma(y_i + \frac{1}{\alpha})}{\Gamma(y_i + 1)\Gamma(\frac{1}{\alpha})} \left(\frac{1}{1 + \alpha\mu_i} \right)^{\frac{1}{\alpha}} \left(\frac{\alpha\mu_i}{1 + \alpha\mu_i} \right)^{y_i} \\ &= \frac{\Gamma(y_i + \frac{1}{\alpha})}{\Gamma(y_i + 1)\Gamma(\frac{1}{\alpha})} \left(\frac{1}{1 + \alpha \exp(X_i \boldsymbol{\beta})} \right)^{\frac{1}{\alpha}} \left(\frac{\alpha \exp(X_i \boldsymbol{\beta})}{1 + \alpha \exp(X_i \boldsymbol{\beta})} \right)^{y_i} \end{aligned}$$

와 같이 정리할 수 있다.

2. 로그가능도 (log-likelihood) 함수

음이항 분포의 로그 가능도함수는 다음과 같다.

$$\log L(\alpha, \boldsymbol{\beta}) = \sum_{i=1}^n \left\{ y_i \log \alpha + \left(y_i + \frac{1}{\alpha} \right) \log(1 + \alpha \exp(X_i \boldsymbol{\beta})) + \log \Gamma\left(y_i + \frac{1}{\alpha}\right) - \log(y_i + 1) - \log \Gamma\left(\frac{1}{\alpha}\right) \right\}$$

3. 음이항분포의 유도

λ 와 u 가 주어졌을 때, y 의 분포를 $f(y_i; \lambda, u) = \frac{e^{-\lambda_i u_i} (\lambda_i u_i)^{y_i}}{y_i!}$ 라 하자.

감마분포에 의해 $g(u)$ 를 정의하는 방법으로부터 y 의 분포는 $u = \exp(\epsilon)$ 이 된다. 여기서 $\log \mu_i = x_i \beta + \epsilon_i$ 이고 평균은 감마분포의 평균과 같다. 감마분포와 u 가 주어졌을 때의 평균을 갖는 포아송분포의 혼합분포의 평균은 u 가 주어졌을 때 y 의 평균이며 분산은 u 가 주어졌을 때 y 의 분산이다. 포아송-감마 혼합분포는 다음과 같이 정의된다.

$$\begin{aligned} f(y_i; \lambda, u) &= \int_0^\infty \frac{e^{-\lambda_i u_i} (\lambda_i u_i)^{y_i}}{y_i!} \frac{v^v}{\Gamma(v)} u_i^{v-1} e^{-v u_i} du_i \\ &= \frac{\lambda_i^{y_i}}{\Gamma(y_i + 1)} \frac{v^v}{\Gamma(v)} \int_0^\infty e^{-\lambda_i u_i} \cdot u_i^{(y_i+v)-1} du_i \\ &= \frac{\Gamma(y_i + v)}{\Gamma(y_i + 1)\Gamma(v)} \cdot \left(\frac{v}{\lambda_i + v} \right)^v \cdot \left(\frac{\lambda_i}{\lambda_i + v} \right)^{y_i} \\ &= \frac{\Gamma(y_i + v)}{\Gamma(y_i + 1)\Gamma(v)} \cdot \left(\frac{1}{1 + \frac{\lambda_i}{v}} \right)^v \cdot \left(1 - \frac{1}{1 + \frac{\lambda_i}{v}} \right)^{y_i} \end{aligned}$$

감마분포의 척도모수 (scale parameter) α 가 v 의 역수 꼴이며, 음이항 분포에서 과산포 (overdispersion)모수 혹은 이질성 (heterogeneity)모수라 부른다. 최종적으로 음이항 분포가 다음과 같이 정의된다.

$$f(y_i; \mu, \alpha) = \frac{\Gamma(y_i + \frac{1}{\alpha})}{\Gamma(y_i + 1)\Gamma(\frac{1}{\alpha})} \cdot \left(\frac{1}{1 + \lambda_i \alpha} \right)^{\frac{1}{\alpha}} \cdot \left(1 - \frac{1}{1 + \lambda_i \alpha} \right)^{y_i}$$

4. 추정방법

α 와 β 는 IRLS (iteratively reweighted least square)로 추정한다. 이 방법은 피셔 스코어 함수 (Fisher score function)를 이용하는 방법이며, 이는 1차 미분한 행렬로 선형모형을 추정하기 위해 사용되는 최대 우도 (ML; maximum likelihood) 추정의 일부이다.

지수족 분포는 $f(y_i; \theta, \phi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{\alpha_i(\phi)} + c(y_i; \phi) \right\}$ 와 같이 나타내어지는데, 여기서 θ_i 는 정준 모수 (canonical parameter) 또는 연결함수이고, $b(\theta_i)$ 는 누적량 (cumulant), $\alpha(\phi)$ 는 척도모수, $c(y_i; \phi)$ 는 정규화 상수 (normalization term)이다. 지수족 분포의 장점은 특정 분포의 θ 에 대한 1차, 2차미분으로부터 유일한 (unique)한 평균과 분산을 알 수 있다는 것이다:

$$b'(\theta_i) = \text{mean}, \quad b''(\theta_i) = \text{variance}$$

일반화 선형모형의 pdf는 $f(y_i; \theta, \phi)$ 이고 여기서 y_i 는 반응변수 (response variable), θ_i 는 위치모수 (location parameter), ϕ 는 척도모수이다. 로그 가능도함수를 $L(\theta_i, \phi; y_i)$ 라 하면 IRLS는 테일러 전개 (Taylor expansion)를 기반으로 유도된다:

$$0 = f(y_0) + f(y_1 - y_0)f'(y_0) + \frac{(y_1 - y_0)^2}{2!}f''(y_0) + \dots$$

처음 두 번째 항까지만 고려하면,

$$\begin{aligned} 0 &= f(y_0) + f(y_1 - y_0)f'(y_0) \\ \Rightarrow y_1 &= y_0 - \frac{f(y_0)}{f'(y_0)} \end{aligned}$$

의 관계식을 얻는다.

로그 가능도 함수는 최대점 (peak)이 존재한다. ML추정은 그라디언트 (gradient) 혹은 피셔 스코어 (로그 가능도함수의 β 에 대한 1차 도함수)를 0으로 놓고 푸는 것이다. 로그 가능도 함수의 2차 도함수 행렬을 정보행렬 (information matrix) 또는 헤시안 행렬 (Hessian matrix)라고 부르며 분산-공분산 행렬이 된다. 분산-공분산 행렬의 대각원소로부터 추정량의 표준오차를 알 수 있다.

IRLS 알고리즘의 설명을 위해 로그 가능도 함수의 1차 도함수 행렬을 U 로, 2차 도함수 행렬을 H 로 표기하자:

$$U = \partial L, \quad H = \partial^2 L$$

뉴턴-랩슨 (Newton-Raphson) 알고리즘을 이용한 모수 추정값은

$$\beta^+ \rightarrow \beta - H^{-1}U$$

를 반복함으로써 얻는다. 로그 가능도 함수는 지수족의 형태로 $L(\theta_i; y_i, \phi) = \sum_{i=1}^n \frac{y_i \theta_i - b(\theta_i)}{a_i(\phi)} + c(y_i; \phi)$ 이고, β_j 에 대하여 L 을 풀기위해 연쇄법칙 (chain rule)을 이용하면

$$\frac{\partial L}{\partial \beta_j} = \sum_{i=1}^n \frac{\partial L}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_j}$$

와 같이 전개할 수 있다. 각 term 을 차례대로 풀면,

$$\frac{\partial L}{\partial \beta_j} = \sum_{i=1}^n \frac{y_i \theta_i - b'(\theta_i)}{a_i(\phi)} + \sum_{i=1}^n \frac{y_i - \mu_i}{a_i(\phi)}$$

이고, $b'(\theta_i) = \mu_i$ 임을 이용하여 두 번째 term

$$\begin{aligned} \frac{\partial \mu_i}{\partial \theta_i} &= \frac{\partial b'(\theta_i)}{\partial \theta_i} = b''(\theta_i) = V(\mu_i) \\ \Rightarrow \frac{\partial \theta_i}{\partial \mu_i} &= \frac{1}{V(\mu_i)} \end{aligned}$$

을 얻을 수 있다.

그리고 $\eta_i = X_i^T \beta_j$ 이므로 네 번째 term,

$$\frac{\partial \eta_i}{\partial \beta_j} = \frac{\partial (X_i^T \beta_j)}{\partial \beta_j} = X_{ij}$$

을 얻을 수 있다. 그리고 세 번째 term,

$$\frac{\partial \mu_i}{\partial \eta_i} = [g^{-1}(\eta_i)]' = \frac{1}{\frac{\partial \eta_i}{\partial \mu_i}} = \frac{1}{g'(\mu_i)}$$

을 얻는다. 또한 μ_i 의 η_i 에 대한 미분은 연결함수의 역수임을 이용한다:

$$\sum_{i=1}^n \frac{(y_i - \mu_i)x_i}{a_i(\phi)V(\mu_i)g'(\mu_i)} = \sum_{i=1}^n \frac{(y_i - \mu_i)x_i}{a_i(\phi)V(\mu_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right) = 0$$

여기서 y_i 는 반응변수, μ_i 는 적합된 변수 (fitted variable)이다. 정보행렬을 $I = E \left[\frac{\partial^2 L}{\partial \beta_j \partial \beta_k} \right] = E \left[\frac{\partial L}{\partial \beta_j} \frac{\partial L}{\partial \beta_k} \right]$ 라 놓으면 다음과 같이 전개할 수 있다:

$$\begin{aligned}
I &= \frac{\partial}{\partial \beta_j} \left[\frac{(y_i - \mu_i)x_j}{a_i(\phi)V(\mu_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right) \right] \cdot \frac{\partial}{\partial \beta_k} \left[\frac{(y_i - \mu_i)x_k}{a_i(\phi)V(\mu_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right) \right] \\
&= \frac{(y_i - \mu_i)^2 x_j x_k}{\{a_i(\phi)V(\mu_i)\}^2} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2
\end{aligned}$$

이 때, $(y_i - \mu_i)^2 = a_i(\phi)V(\mu_i)$ 이므로 $V(y_i) = a_i(\phi)V(\mu_i) = (y_i - \mu_i)^2$ 라 하면

$$I = \frac{x_j x_k}{V(y_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 = \frac{x_j x_k}{V(y_i)g'^2}$$

이 성립한다. 따라서 뉴턴-랩슨 알고리즘은

$$\beta^+ \leftarrow \beta - \left[\frac{x_j x_k}{V(y_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 \right]^{-1} \cdot \left[\frac{(y_i - \mu_i)x_k}{V(y_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right) \right]$$

이 된다.

계속해서 역함수 term을 양 변에 곱해보자:

$$\left[\frac{x_j x_k}{V(y_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 \right] \beta^+ = \left[\frac{x_j x_k}{V(y_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 \right] \beta + \left[\frac{(y_i - \mu_i)x_k}{V(y_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right) \right]$$

여기서 $W = \frac{1}{V(y_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2$ 라 놓으면 선형 예측자 (linear predictor) $\eta_i = X_i \beta$ 에 대하여 왼쪽 항은

$$\left[\frac{x_j x_k}{V(y_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 \right] \beta^+ = (X^T W X) \beta^+$$

로 표현되며, 오른 쪽 첫번째 항은

$$\left[\frac{x_j x_k}{V(y_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 \right] \beta = X^T W \eta_i$$

이 되고, W 와 $V(y_i)$ 의 정의에 의하여 오른쪽 두 번째 항은

$$\frac{(y_i - \mu_i)x_k}{V(y_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right) = \frac{(y_i - \mu_i)x_k}{\frac{1}{W} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2} \left(\frac{\partial \mu_i}{\partial \eta_i} \right) = x_k W (y_i - \mu_i) \left(\frac{\partial \mu_i}{\partial \eta_i} \right)$$

으로 표현할 수 있다.

정리하면

$$\begin{aligned}
(X^T W X) \beta^+ &= X^T W \eta_i + x_k W (y_i - \mu_i) \left(\frac{\partial \mu_i}{\partial \eta_i} \right) \\
&= X^T W \eta_i + \frac{(y_i - \mu_i)x_k}{\frac{1}{W} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)
\end{aligned}$$

이고, $z_i = \eta_i + (y_i - \mu_i) \left(\frac{\partial \mu_i}{\partial \eta_i} \right)$ 라 놓으면 최종적으로

$$(X^T W X) \beta^+ = X^T W Z$$

$$\Rightarrow \beta^+ = (X^T W X)^{-1} W Z$$

를 얻는다.

5. 예시

5-1. 로지스틱 회귀

확률변수 Y_i 가 $B(n_i, p_i)$ 를 따른다고 가정하고 성공의 비율 Y_i/n_i 을 모델링하는 것이 목적으로 두자. 그러면 비율의 평균과 분산은 각각 $\mathbb{E}(Y_i/n_i) = p_i$, $V(Y_i/n_i) = p_i(1 - p_i)/n_i$ 이다. 따라서 분산 함수는 $V(\mu_i) = \mu_i(1 - \mu_i)$ 이다. 연결함수는 $\eta_i : (0, 1) \mapsto (-\infty, \infty)$ 이며, 다음과 같은 형태를 갖는다:

$$\eta_i = \text{logit } \mu_i = \log \frac{\mu_i}{1 - \mu_i}$$

로지스틱 회귀에서의 연결함수 η_i , working response z_i 와 weights w_i 는 다음과 같이 정리된다.

$$\eta_i = \text{logit } \mu_i,$$

$$z_i = \eta_i + (y_i - \mu_i) \frac{\partial \mu_i}{\partial \eta_i} = \eta_i + \frac{y_i - \mu_i}{\mu_i(1 - \mu_i)},$$

$$w_i = \frac{1}{V(\mu_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 = \mu_i(1 - \mu_i)$$

5-2. 포아송 회귀

확률변수 Y_i 가 $\text{Poisson}(\mu_i)$ 를 따른다고 가정하자. 그러면 Y_i 의 평균과 분산은 각각 $\mathbb{E}(Y_i) = \mu_i$, $V(Y_i) = \mu_i$ 이다. 따라서 분산 함수는 $V(\mu_i) = \mu_i$ 이다. 연결함수는 $\eta_i : (0, \infty) \mapsto (-\infty, \infty)$ 이며, 다음과 같은 형태를 갖는다:

$$\eta_i = \log \mu_i$$

포아송 회귀에서의 연결함수 η_i , working response z_i 와 weights w_i 는 다음과 같이 정리된다.

$$\eta_i = \log \mu_i,$$

$$z_i = \eta_i + (y_i - \mu_i) \frac{\partial \mu_i}{\partial \eta_i} = \eta_i + \frac{y_i - \mu_i}{\mu_i},$$

$$w_i = \frac{1}{V(\mu_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 = \mu_i$$

5-3. 음이항 회귀

확률변수 Y_i 가 $NB(\mu_i, \phi)$ 를 따른다고 가정하자. 그러면 Y_i 의 평균과 분산은 각각 $\mathbb{E}(Y_i) = \mu_i$, $\text{Var}(Y_i) = \mu_i + \frac{\mu_i^2}{\phi}$ 이다. 따라서 분산 함수는 $V(\mu_i) = \mu_i + \frac{\mu_i^2}{\phi}$ 이다. 연결함수는 $\eta_i : (0, \infty) \mapsto (-\infty, \infty)$ 이며, 다음과 같은 형태를 갖는다:

$$\eta_i = \log \mu_i$$

음이항 회귀에서의 연결함수 η_i , working response z_i 와 weights w_i 는 다음과 같이 정리된다.

$$\begin{aligned}\eta_i &= \log \mu_i, \\ z_i &= \eta_i + (y_i - \mu_i) \frac{\partial \mu_i}{\partial \eta_i} = \eta_i + \frac{y_i - \mu_i}{\mu_i}, \\ w_i &= \frac{1}{V(y_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 = \frac{1}{\mu_i + \frac{\mu_i^2}{\phi}} \frac{1}{\mu_i^2} = \frac{1}{1 + \mu_i \phi^{-1}}\end{aligned}$$

6. 시뮬레이션

가능도함수는 다음과 같이 정의된다:

$$L(\boldsymbol{\beta}, \alpha; y_1, \dots, y_n) = \prod_{i=1}^n f(y_i; \mu, \alpha)$$

이에 따라 로그 가능도함수는 다음과 같이 정의된다:

$$\log L = \sum_{i=1}^n \left[\sum_{k=1}^{y_i-1} \log(1 + \alpha y_i - \alpha k) - y_i \log(1 + \alpha \mu_i) - \frac{\log(1 + \alpha \mu_i)}{\alpha} + y_i \log \mu_i - \log y_i \right]$$

모수벡터를 $\theta = (\boldsymbol{\beta}^T, \alpha)^T$ 로 정의할 때, score function은 다음과 같이 정의된다:

$$S(\theta) = \begin{bmatrix} \frac{\partial \log L}{\partial \boldsymbol{\beta}} \\ \frac{\partial \log L}{\partial \alpha} \end{bmatrix}$$

여기서 구체적인 값은 다음과 같이 계산되는 값이다:

$$\begin{aligned}\frac{\partial \log L}{\partial \boldsymbol{\beta}} &= \sum_{i=1}^n \left[\frac{x_i(y_i - \mu_i)}{1 + \alpha \mu_i} \right] \\ \frac{\partial \log L}{\partial \alpha} &= \sum_{i=1}^n \left[\sum_{k=1}^{y_i} \frac{y_i - k}{1 + \alpha y_i - \alpha k} - \frac{y_i \mu_i}{1 + \alpha \mu_i} - \frac{\mu_i}{\alpha(1 + \alpha \mu_i)} + \frac{\log(1 + \alpha \mu_i)}{\tau^2} \right]\end{aligned}$$

그리고 2차 도함수 행렬인 Hessian matrix는 다음과 같이 구성되며,

$$H(\theta) = \begin{bmatrix} \frac{\partial^2 \log L}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}^T} & \frac{\partial^2 \log L}{\partial \boldsymbol{\beta} \partial \alpha} \\ \frac{\partial^2 \log L}{\partial \alpha \partial \boldsymbol{\beta}} & \frac{\partial^2 \log L}{\partial \alpha^2} \end{bmatrix}$$

구체적으로 계산되는 값 역시 다음과 같다:

$$\begin{aligned}\frac{\partial^2 \log L}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}^T} &= \sum_{i=1}^n \left[-\frac{\mu_i(1 + \alpha y_i) x_i x_i^T}{(1 + \alpha \mu_i)^2} \right] \\ \frac{\partial^2 \log L}{\partial \boldsymbol{\beta} \partial \alpha} &= \sum_{i=1}^n \left[-\frac{(y_i - \mu_i) x_i}{(1 + \alpha \mu_i)^2} \right] \\ \frac{\partial^2 \log L}{\partial \alpha^2} &= \sum_{i=1}^n \left[-\sum_{k=1}^{y_i} \frac{(y_i - k)^2}{(1 + \alpha y_i - \alpha k)} + \frac{\mu_i^2 y_i}{(1 + \alpha \mu_i)^2} + \frac{\mu_i(1 + 2\alpha \mu_i)}{\alpha^2(1 + \alpha \mu_i)^2} + \frac{\mu_i}{\alpha^2(1 + \alpha \mu_i)} - \frac{2 \log(1 + \alpha \mu_i)}{\alpha^3} \right]\end{aligned}$$

다음으로 시뮬레이션에 사용될 함수를 지정하자. 여기서 `Dvec`은 가능도함수의 1차 도함수 벡터, `Hmat`은 가능도함수의 2차 도함수 행렬이다.

```
Dvec = function(x, y, mu, tau){
  n = dim(x)[1]
  p = dim(x)[2]

  dbeta = c()
  for(j in 1:p){
    dbeta[j] = sum( x[,j] * (y-mu) / (1 + tau * mu) )
  }

  vv = c()
  for(i in 1:n){
    vv[i] = 0
    if(y[i] != 0) for(v in 0:(y[i]-1)) vv[i] = vv[i] + 1/(v+tau^{-1})
  }

  dtau = sum(tau^{-2} * (log(1+tau*mu) - vv) + (y-mu)/tau/(1+tau*mu))

  return(c(dbeta, dtau))
}

###

Hmat = function(x, y, mu, tau){
  n = dim(x)[1]
  p = dim(x)[2]

  ddbeta = matrix(0, p, p)
  for(j in 1:p){
    for(k in 1:p){
      ddbeta[j, k] = sum( mu*(1+tau*y)*x[,j]*x[,k] / (1+tau*mu)^2 )
    }
  }

  ddbetatau = c()
  for(j in 1:p){
    ddbetatau[j] = sum( mu*(y-mu)*x[,j]/(1+tau*mu)^2 )
  }

  vv = c()
  for(i in 1:n){
    vv[i] = 0
    if(y[i] != 0) for(v in 0:(y[i]-1)) vv[i] = vv[i] + (v/1+tau*v)^2
  }

  ddttau = sum( vv + 2*tau^{-3}*log(1+tau*mu)-(2*tau^{-2}*mu)/(1+tau*mu)
    - (y+tau^{-1}*mu^2)/(1+tau*mu)^2)

  Hessian = cbind(rbind(ddbeta, ddbetatau), c(ddbetatau, ddttau))
  rownames(Hessian) = NULL
}
```

```

    return( Hessian )
}

```

모수벡터 θ 의 추정은 뉴턴-랩슨알고리즘으로 한다:

$$\theta^{(t+1)} = \theta^{(t)} + [-H(\theta^{(t)})]^{-1}[S(\theta^{(t)})], \quad t = 0, 1, 2, 3, \dots$$

뉴턴랩슨 알고리즘도 함수로 정의해준다:

뉴턴랩슨 알고리즘

```

NewtonRaphson = function(x, y){
  n = dim(x)[1]
  p = dim(x)[2]

  max_iter = 200
  eps = 1e-5

  theta = runif(p+1, 0.3, 0.5) # (beta, tau)
  theta_new = 100

  t = 0
  while(sum((theta-theta_new)^2) > eps || t < max_iter){
    t = t + 1

    if(t != 1){ # update
      theta = theta_new
    }
    mu_new = exp(x %*% theta[1:p]) # theta[1:p] is mu
    tau_new = theta[p+1]           # theta[p+1] is tau

    D = Dvec(x, y, mu_new, tau_new)
    H = Hmat(x, y, mu_new, tau_new)

    theta_new = theta + solve(H) %*% D

    # cat("iteration =", t, "|| theta_new =", theta_new, '\n')
    # cat("loss =", norm(theta-theta_new), '\n')
  }

  rownames(theta_new) = c(paste0("beta", (1:p)-1), "tau")

  return(theta_new)
}

```

분석에 사용할 데이터는 UCLA에서 다운받은 예시 데이터를 사용하였다. num_awards는 계수형의 결과 변수이며 고등학교에서 1년에 받은 상 수를 나타내고, math는 연속형 예측 변수로 수학 기말고사에서 학생의 점수를 나타낸다. 마지막으로 prog는 범주형 예측 변수로 학생들이 등록한 프로그램의 유형을 나타내는 세 가지 수준 1(General, 일반), 2(Academic, 학업), 3(Vocational, 직업)을 의미한다. 연속형인 math 변수는 scaling을 해주었고, 범주형인 prog 변수는 General을 baseline으로 하여 나머지 Academic과 Vocational을 더미변수로 바꾸어주었다. 반응변수인 num_awards는 평균이 0.63, 분산이 1.109로 과산포가 존재하기에 음이항 회귀무형을 사용하기에 적합하다고 할 수 있다. 더 큰 마지막으로 NewtonRaphson 함수에 넣기 위해 해당 데이터를 design matrix로 바꾸어주었다.

```

dat = read.csv("https://stats.idre.ucla.edu/stat/data/poisson_sim.csv")
dat$id = NULL

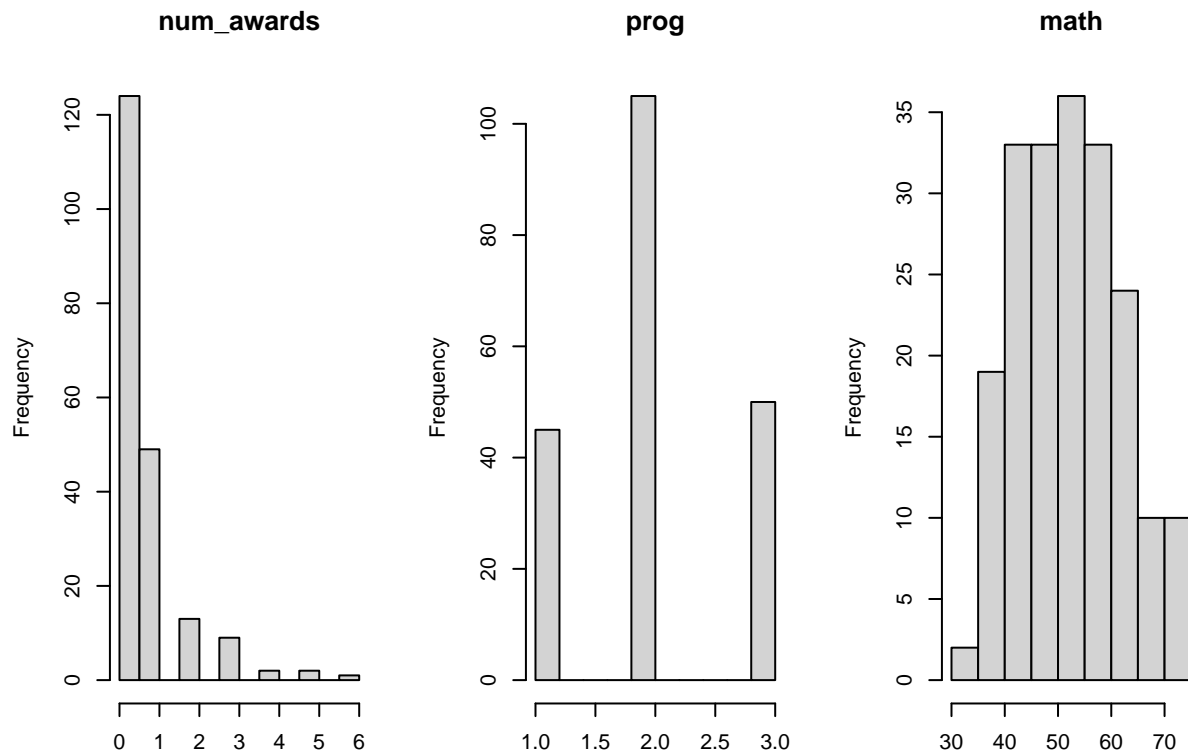
```



```
summary(dat)
```

```
##      num_awards      prog      math
##  Min.   :0.00   Min.   :1.000   Min.   :33.00
##  1st Qu.:0.00   1st Qu.:2.000   1st Qu.:45.00
##  Median :0.00   Median :2.000   Median :52.00
##  Mean    :0.63   Mean    :2.025   Mean    :52.65
##  3rd Qu.:1.00   3rd Qu.:2.250   3rd Qu.:59.00
##  Max.    :6.00   Max.    :3.000   Max.    :75.00
```

```
par(mfrow = c(1, 3))
for(i in 1:ncol(dat)) hist(dat[,i], main = paste0(colnames(dat)[i]), xlab = '') # 히스토그램
```



```
cat('num_awards의 평균 =', mean(dat$num_awards), '\n')
```

```
## num_awards의 평균 = 0.63
```

```
cat('num_awards의 분산 =', var(dat$num_awards), '\n')
```

```
## num_awards의 분산 = 1.108643
```

```
# 데이터 형식 변환
```

```
dat$math = as.numeric(dat$math) # int -> numeric으로 변환
```

```
dat$prog = factor(dat$prog, levels=1:3, labels=c("General", "Academic", "Vocational"))
```

```
# prog변수를 dummy variable로 변환 (base를 General로 함)
```

```
dat$Academic = ifelse(dat$prog == 'Academic', 1, 0)
```

```
dat$Vocational = ifelse(dat$prog == 'Vocational', 1, 0)
```

```
# design matrix
X = dat
X$prog = NULL
X$num_awards = NULL
X$math = scale(X$math)
X = as.matrix(X)
X = cbind(1, X)

y = dat$num_awards
head(X)
```

```
##           math Academic Vocational
## [1,] 1 -1.2430021      0          1
## [2,] 1 -1.2430021      0          0
## [3,] 1 -0.9227783      0          1
## [4,] 1 -1.1362608      0          1
## [5,] 1 -1.3497433      0          1
## [6,] 1 -1.1362608      0          0
```

```
head(y)
```

```
## [1] 0 0 0 0 0 0
```

뉴튼-랩슨 알고리즘의 결과와 glm.nb의 결과를 비교해보자. beta 추정치들은 비슷하며, 뉴튼랩슨에서의 tau 추정값의 역수는 glm.nb의 추정값과 같으므로 알고리즘이 잘 작동함을 확인하는 것으로 글을 마친다.

```
library(MASS)
NewtonRaphson(X, y) # 방법 1
```

```
##           [,1]
## beta0 -1.5518980
## beta1  0.6658039
## beta2  1.0750711
## beta3  0.3669593
## tau    0.1635413
```

```
summary(glm.nb(y ~ X[, -1])) # 방법 2
```

```
##
## Call:
## glm.nb(formula = y ~ X[, -1], init.theta = 6.114661779, link = log)
##
## Deviance Residuals:
##      Min       1Q   Median       3Q      Max
## -2.0322  -0.8343  -0.5039   0.2276   2.3222
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -1.5519     0.3397  -4.568 4.92e-06 ***
## X[, -1]math      0.6658     0.1080   6.165 7.05e-10 ***
## X[, -1]Academic  1.0751     0.3670   2.929  0.0034 **
## X[, -1]Vocational 0.3670     0.4523   0.811  0.4172
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(6.1147) family taken to be 1)
```

```
##
##      Null deviance: 257.93  on 199  degrees of freedom
## Residual deviance: 169.76  on 196  degrees of freedom
## AIC: 373.81
##
## Number of Fisher Scoring iterations: 1
##
##
##           Theta:  6.11
##          Std. Err.:  5.58
##
## 2 x log-likelihood: -363.811
```